

ASSIGNATION ET DÉTECTION DES PARTIES TRANSMEMBRANAIRES D'UNE PROTÉINE

Eve-Angeline STEPHEN

UE BQ4CE025 Gestion de projet informatique et programmation avancée

M2 Biologie Informatique

Université Paris Cité

Dépôt GitHub : github.com/Eve-Ast/TMDET_BI

2026-2027

RÉSUMÉ

Ce projet propose un algorithme inspiré de TMDET permettant d'identifier, à partir de la structure tridimensionnelle d'une protéine, l'orientation et la position probables de la bicouche lipidique. Deux méthodes de détection fondées sur l'hydrophobicité des résidus exposés et leur projection sur différents axes ont été implémentées et comparées. Les résultats montrent que la seconde méthode est plus performante pour la porine 1PRN, avec une orientation cohérente avec la référence OPM, tandis que les performances sont limitées pour la bactériorhodopsine 1QHJ. L'absence de critères géométriques, présents dans l'algorithme TMDET original, semble notamment limiter la généralisation aux structures α -hélicoïdales.

1. INTRODUCTION

Les protéines transmembranaires représentent une fraction importante du protéome (environ 20 à 30%) et une cible majeure des médicaments. Cependant, la Protein Data Bank (PDB) ne contient seulement qu'une centaine de protéines transmembranaires du à la difficulté des techniques expérimentales. Même si une protéine est identifiée comme transmembranaire dans la PDB, la localisation de sa bicouche lipidique n'est pas indiquée car ces protéines sont cristallisées sans leur bicouche lipidique naturelle.[1] La détection des segments membranaires reposait presque uniquement sur l'analyse de la séquence protéique, exploitant le caractère hydrophobes des hélices membranaires et ignore totalement l'information structurale 3D. De nombreux outils ont ainsi été développés au fil des années, notamment TMHMM, s'appuyant sur des modèles de Markov cachés. [2, 3]. Elles ne permettent donc pas de localiser précisément le plan de la membrane par rapport à une structure résolue expérimentalement,

ni de distinguer de façon fiable une hélice réellement transmembranaire d'une hélice simplement hydrophobe en surface.

Dans le cadre de ce projet, nous avons développé un programme d'assignation et de détection des parties transmembranaire d'une protéine inspirée de l'algorithme TMDET décrit par Tusnády, Dosztányi et Simon [1]. L'approche proposée utilise uniquement l'information structurale pour distinguer les protéines transmembranaires des protéines globulaires et pour localiser la position la plus probable de la bicouche lipidique. L'algorithme qu'ils développent détermine les plans de membrane par rapport à la position d'une protéine et permet une annotation appropriée des structures protéiques contenant des segments transmembranaires.

2. MATÉRIELS ET MÉTHODES

2.1. L'environnement

Le script a été développé en Python, version 3.13.5. Le calcul de la surface accessible au solvant (SASA) des résidus a été réalisé à l'aide du logiciel NACCESS version 2.1.1 [4], tandis que la visualisation et l'inspection des structures tridimensionnelles ont été effectuées avec PyMOL, version 3.1.6.1 (Incentive Product, Schrödinger, LLC) [5]. Les bibliothèques de base de Python ont été utilisées tels que argparse, os, shutil, subprocess, math ainsi que le package numpy 2.5.3.

2.2. Les données

Pour tester cet algorithme, les fichiers PDB de deux protéines transmembranaires ont été utilisés (Porine de Rhodopsudomonas Blastica, code PDB : 1PRN et bactériorhodopsine, code PDB : 1QHJ). De plus, afin de comparer les résultats obtenus, les fichier PDB issus de la base de données OPM ont été utilisés.

2.3. L'algorithme

La première étape de l'algorithme est l'exécution du programme externe NACCESS sur le fichier PDB fourni. NACCESS calcule, pour chaque résidu, sa surface accessible au solvant (SASA), absolue et relative, et génère un fichier .rsa. Cette étape nous permettra par la suite de ne conserver que les résidus suffisamment exposés en surface de la protéine (donc potentiellement au contact du milieu lipidique), écartant les résidus enfouis dans le cœur globulaire qui ne sont pas structurellement pertinents pour définir la membrane.

Ensuite un double parsing est réalisée sur le fichier PDB pour extraire les coordonnées cartésiennes de chaque atome C α de la chaîne A et sur le fichier .rsa pour extraire la valeur de SASA relative totale pour chaque résidu de la chaîne A. De plus, chaque résidu est décrit par sa valeur d'hydrophobicité obtenue par correspondance avec l'échelle de Kyte & Doolittle.

La protéine est ensuite recentrée à l'origine du repère avec le calcul de son centre de masse. Ce centrage permet de définir simplement la position de la membrane par un simple décalage scalaire le long de l'axe testé et garantit que l'axe et le plan de la membrane recherchés ne dépendent pas de la position arbitraire de la structure dans le fichier PDB. Un ensemble de $n_points = 1000$ vecteurs unitaires uniformément répartis sur une sphère sont générés selon la méthode de la sphère de Fibonacci (StackOverflow, 2012).

Deux méthodes de balayage ont été implémentées et testées. Dans les deux méthodes, pour chaque axe candidat, seuls les résidus dont la SASA dépasse un seuil minimal de 25 Å² sont conservés et projetés sur l'axe par produit scalaire.

Dans la première méthode, l'intervalle couvert par ces projections est découpé en tranche de 1 Å. Pour chaque tranche, l'hydrophobicité moyenne des résidus qui s'y trouve est calculée, produisant un profil d'hydrophobicité de l'axe. Ensuite, une fenêtre de 30 tranches (équivalent à 30 Å, épaisseur d'une membrane) est glissée le long de l'axe, et calcule pour chaque position de la fenêtre la moyenne des valeurs d'hydrophobicité qu'elle contient. Le score associé à cette position (chaque fenêtre) est donc :

$$\text{score} = \overline{\text{hydro}}_{\text{fenêtre } 30 \text{ Å}} \quad (1)$$

Dans la seconde méthode, un balayage par pas de 1 Å est effectué le long de la projection entre les valeurs minimale et maximale, et chaque position testée représentant un centre de membrane candidat. Un score de contraste est donc calculé entre les

résidus situé dans la tranche et les résidus situé à l'extérieur de la tranche :

$$\text{score} = \overline{\text{hydro}}_{\text{intérieur}} - \overline{\text{hydro}}_{\text{extérieur}} \quad (2)$$

Ce score est maximal lorsque les résidus hydrophobes se concentrent dans la tranche testée et les résidus hydrophiles à l'extérieur.

À l'issue du balayage dans les deux méthodes, l'axe optimal, la position optimale du centre de membrane et le score associé est retourné. Une fenêtre PyMOL est aussi ouverte avec la structure de la protéine étudiée et deux plans superposés, matérialisant les frontières de la bicouche lipidique.

3. RÉSULTATS

3.1. Benchmarking entre les deux méthodes vectorisées et non-vectorisée




FIGURE 1 – Temps d'exécution en fonction du nombre d'axes testés

Dans notre algorithme, la vectorisation intervient sur trois opérations répétées un très grand nombre de fois : la projection des coordonnées des résidus sur l'axe testé, la classification de chaque résidu comme appartenant ou non à la tranche de membrane candidate, et le calcul de la moyenne d'hydrophobicité sur ces groupes de résidus.

La figure 1 présente le temps d'exécution des quatre variantes de l'algorithme (Méthode 1 et méthode 2, chacune en version vectorisée et non vectorisée) en fonction du nombre d'axes testés sur la protéine 1PRN. Les deux méthodes non vectorisées présentent une croissance quasi linéaire du temps d'exécution. La méthode 2 non vectorisée est la plus lente des quatre : à $n_points = 1000$, elle atteint environ 1,45 sec, contre environ 0,6 sec pour la méthode 1 non vectorisée. Le gain apporté par la vectorisation est particulièrement visible pour les deux méthodes. En effet, la version vectorisée de la méthode 1 est environ 3 fois plus rapide que la version non vectorisée à $n_points = 1000$ (0,2 sec

contre 0,55 sec). De même pour la méthode 2, ou l'écart entre la version vectorisée et la version non vectorisée est d'un facteur 3 pour $n_points = 1000$ (1,44 sec pour la version non vectorisée et 0,54 sec pour la version vectorisée).

Ces résultats confirment l'intérêt de la vectorisation NumPy pour ce type de calcul géométrique répétitif, particulièrement pour la Méthode 2 dont la formule de score implique un nombre d'opérations plus élevé par position testée.

3.2. Comparaison des méthode 1 et 2 pour la Porine de Rhodopsudomonas Blastica




FIGURE 2 – Résultats de détection membranaire pour 1PRN (Méthode 1, Méthode 2, référence OPM).

On peut voir sur la figure 2 que le plan de membrane déterminé par la Méthode 1 (figure 2A) traverse la protéine selon un axe qui coupe le pore central du tonneau β , une orientation incompatible avec la disposition réelle d'une porine dans la membrane, où le pore doit rester perpendiculaire au plan lipidique et non le traverser. À l'inverse, le plan déterminé par la Méthode 2 (panneau 2B) est bien orienté perpendiculairement à l'axe du tonneau, cohérent avec la référence OPM (panneau 2C), qui positionne la bicouche lipidique de la même manière, encerclant le tonneau sans intersecter le canal central. Cette observation est cohérente avec la différence de formulation des deux scores : la Méthode 1 maximise uniquement l'hydrophobicité moyenne à l'intérieur de la fenêtre testée tandis que la Méthode 2 semble mieux capturer la nature de la membrane comme une région qui doit être à la fois hydrophobe et distincte de son environnement.

3.3. Vérification de la généralisation sur une protéine constitué d'hélice α




FIGURE 3 – Résultats de détection membranaire pour 1QHJ (Méthode 1, Méthode 2, référence OPM).

Afin de vérifier que l'algorithme est généralisé sur les deux topologies de protéines transmembranaire, l'algorithme a été testé sur la protéine de la bacteriorhodopsin (code PDB : 1QHJ). Comme nous pouvons le voir sur la Figure 3, les plans obtenus sont complètement différents de la référence obtenue sur OPM. Un β -tonneau (1PRN) a une alternance hydrophobe/hydrophile très régulière et un grand nombre de résidus exposés bien répartis sur toute la circonférence – ce qui donne un signal de contraste fort et stable. Un faisceau de quelques hélices a beaucoup moins de résidus exposés, un signal plus faible et plus sensible au bruit, ce qui expliquerait le manque de robustesse sur les structure α -hélicale.

4. DISCUSSIONS

Contrairement à l'algorithme TMDet, qui combine un facteur d'hydrophobicité et un facteur structural (régularité géométrique de la chaîne, évaluée via les critères de rectitude, de virage et de fin de chaîne calculés sur les $C\alpha$ projetés le long de l'axe testé), notre implémentation ne repose que sur le premier de ces deux critères. Le score de contraste hydrophobe utilisé évalue uniquement si les résidus exposés dans la tranche testée sont globalement plus hydrophobes que ceux situés à l'extérieur, sans tenir compte de la géométrie locale de la chaîne peptidique. Or, ce facteur structural a précisément pour rôle, dans l'algorithme original, de distinguer un véritable segment transmembranaire (rectiligne) d'un

simple regroupement fortuit de résidus hydrophobes exposés en surface, comme une poche de liaison ou une interface d'oligomérisation.

L'absence de ce facteur géométrique explique vraisemblablement la limitation observée sur 1QHJ (bactériorhodopsine, structure entièrement α -hélicoïdale à 7 hélices) : l'axe détecté par notre algorithme est mal orienté par rapport à la référence OPM, alors que le même algorithme fonctionne de façon satisfaisante sur 1PRN (tonneau β). Un faisceau compact de plusieurs hélices présente naturellement plusieurs axes candidats produisant un contraste hydrophobe comparable (par exemple selon une diagonale du faisceau plutôt que selon son axe central), en l'absence d'un critère supplémentaire favorisant les segments de chaîne rectilignes le long de l'axe testé. Un tonneau β , dont la surface externe est plus homogène et dont la géométrie est intrinsèquement plus contrainte, est en comparaison moins sensible à cette ambiguïté, ce qui pourrait expliquer pourquoi notre méthode généralise mal aux protéines à hélices α sans souffrir des mêmes limites sur les tonneaux β .

Deux pistes d'amélioration découlent directement de ce constat. Premièrement, on pourrait ajouter un facteur géométrique de régularité au score actuel, inspiré du facteur de structure de TMDET, afin de pénaliser les tranches dominées par des résidus de boucle même lorsqu'ils sont fortuitement hydrophobes, et de départager les axes candidats à contraste hydrophobe équivalent. De plus, on pourrait rendre le calcul de surface accessible dépendant de l'axe testé, en filtrant dynamiquement les résidus considérés comme « exposés à la membrane » selon leur position par rapport à chaque axe candidat (par découpage en tranches, comme le fait TMDET), plutôt que d'utiliser un seuil de SASA global et

statique calculé une seule fois, indépendamment de l'orientation testée. Cette dépendance à l'axe est particulièrement importante pour un faisceau d'hélices, où la surface réellement exposée au lipide varie fortement selon la direction considérée, contrairement à un tonneau β dont la surface externe reste globalement exposée quel que soit l'axe.

Ces deux améliorations, toutes deux directement inspirées de la définition du Q-value dans l'article original, constituent une suite naturelle à ce travail pour rapprocher notre approche géométrique simplifiée de la robustesse démontrée par TMDET sur l'ensemble des topologies membranaires.

RÉFÉRENCES

1. Tusnády, Gábor E., et al. « Transmembrane Proteins in the Protein Data Bank : Identification and Classification ». *Bioinformatics*, vol. 20, no 17, novembre 2004, p. 2964–72. DOI.org (Crossref), doi.org/10.1093/bioinformatics/bth340.
2. Möller, Steffen, et al. « Evaluation of Methods for the Prediction of Membrane Spanning Regions ». *Bioinformatics*, vol. 17, no 7, juillet 2001, p. 646–53. DOI.org (Crossref), doi.org/10.1093/bioinformatics/17.7.646.
3. Krogh, Anders, et al. « Predicting Transmembrane Protein Topology with a Hidden Markov Model : Application to Complete genomes » Edited by F. Cohen ». *Journal of Molecular Biology*, vol. 305, no 3, janvier 2001, p. 567–80. DOI.org (Crossref), doi.org/10.1006/jmbi.2000.4315.
4. Hubbard, S.J. and Thornton, J.M. (1993) 'NACCESS', computer program. Department of Biochemistry and Molecular Biology, University College, London.
5. The PyMOL Molecular Graphics System, Version 3.0 Schrödinger, LLC.